

Selección de Muestra — Horas de Sueño, Ecuaciones Diferenciales 2026-01

Muestreo Aleatorio Simple (MAS)

Luis Miguel Duque, Gerson Bayona Aro, Sara Jurado, Samir Centeno

1. Justificación del cambio de diseño

En la propuesta original se planteó un **Muestreo Aleatorio Estratificado (MAE)**, usando el horario de clase como variable de estratificación. Sin embargo, el marco muestral entregado por el coordinador de la asignatura únicamente contiene **nombres y apellidos** de los 1130 estudiantes matriculados, sin información de grupo ni horario. Al no contar con esa variable, no es posible construir los estratos, por lo que se ajusta el diseño a un **Muestreo Aleatorio Simple (MAS)** sobre la totalidad del marco muestral.

2. Parámetros y cálculo del tamaño de muestra

Se usa la fórmula de MAS para estimación de una media, con corrección por población finita:

$$n_0 = \frac{Z^2 \cdot S^2}{e^2} \qquad n = \frac{n_0}{1 + n_0/N}$$

```
N <- 1130      # tamaño de la población (marco muestral entregado)
Z <- 1.96      # confianza del 95%
S <- 1.5       # desviación estándar supuesta de horas de sueño (ajustar si el
               # profesor exige otro valor o si consiguen una referencia mejor)
e <- 0.5       # error máximo admisible, en horas

n0 <- (Z^2 * S^2) / e^2
n  <- ceiling(n0 / (1 + n0 / N))

n0
```

```
[1] 34.5744
```

n

[1] 34

Nota: $S = 1.5$ es un supuesto razonable (rango típico de sueño de 4 a 10 horas, usando la regla práctica $S = \text{rango}/4$), ya que los antecedentes citados en la propuesta (Zapata-López et al., 2024) reportan calidad de sueño (PSQI) y no la desviación estándar en horas. Si el profesor pide sustentar mejor este valor, basta con cambiar S en este chunk y todo el documento se recalcula.

2.1 Limitación del supuesto y estimación en dos etapas

El valor $S = 1.5$ es una **suposición inicial**, no un dato observado. Como el tamaño de muestra depende directamente de qué tan variable es realmente el sueño de los estudiantes (y no del tamaño de la población, que aquí casi no influye por ser N grande), un supuesto equivocado de S puede dejar la muestra sub-dimensionada. Por eso se sigue un procedimiento en dos etapas, estándar en diseño muestral cuando no existe información previa confiable de la varianza:

1. **Etapla piloto:** se encuesta un subconjunto pequeño de la muestra ya seleccionada (por ejemplo, los primeros 15 estudiantes de los 34).
2. **Recalcular S :** con las respuestas del piloto se calcula la desviación estándar muestral real (`sd()` en R).
3. **Recalcular n :** se reemplaza el S supuesto por el S observado en la misma fórmula del punto 2.
4. **Completar la muestra:** si el nuevo n es mayor que 34, se seleccionan estudiantes adicionales del marco muestral (misma semilla, excluyendo a quienes ya fueron seleccionados) hasta alcanzar el n recalculado.

```
# Una vez se tengan las respuestas del piloto (vector de horas de sueño):
piloto <- c() # completar con las horas reportadas por el piloto

S_real <- sd(piloto)
n0_real <- (Z^2 * S_real^2) / e^2
n_real <- ceiling(n0_real / (1 + n0_real / N))

n_real

# Si n_real > n, seleccionar los estudiantes faltantes excluyendo los ya elegidos
faltantes <- n_real - n
if (faltantes > 0) {
  set.seed(2026)
  complemento <- datos |>
```

```

    anti_join(muestra, by = c("NOMBRES", "PRIMER_APELLIDO", "SEGUNDO_APELLIDO")) |>
    slice_sample(n = faltantes)
muestra_final <- bind_rows(muestra, complemento)
} else {
  muestra_final <- muestra
}

```

3. Carga del marco muestral

```

library(readxl)
library(dplyr)

```

Warning: package 'dplyr' was built under R version 4.6.1

```

datos <- read_excel("Lista Estudiantes ED(Sara) (1).xlsx", sheet = "Sheet2") |>
  filter(!is.na(NOMBRES))

```

```
nrow(datos) # debe ser 1130
```

```
[1] 1130
```

```
head(datos)
```

```

# A tibble: 6 x 3
  NOMBRES          PRIMER_APELLIDO SEGUNDO_APELLIDO
  <chr>            <chr>            <chr>
1 Sara Gabriela Cardozo      Ramírez
2 JUAN ESTEBAN   BARRERA        ESCUDERO
3 Sara           Gutierrez      Bahamon
4 Simon          Cardona        Yepes
5 Yery Vanesa    Presiga        Villada
6 JUAN SEBASTIAN HOYOS        CASTILLO

```

4. Selección de la muestra (MAS)

Se fija una semilla para que la selección sea completamente reproducible por cualquier integrante del grupo.

```
set.seed(2026) # semilla fija - no cambiar, garantiza reproducibilidad
```

```
muestra <- datos |>
  slice_sample(n = n)
```

```
muestra
```

```
# A tibble: 34 x 3
```

	NOMBRES	PRIMER_APELLIDO	SEGUNDO_APELLIDO
	<chr>	<chr>	<chr>
1	JOSE ALEJANDRO	ESCUDERO	ZAPATA
2	JUAN JOSÉ	GIRÓN	BECERRA
3	TOMÁS UBERNEY	GÓMEZ	GONZÁLEZ
4	Tomas Eduardo	Navarro	Dominguez
5	SANTIAGO	VAHOS	CANO
6	Laura Cristina	Soto	Blandon
7	Brayan David	Caballero	Fernández
8	KATHERINE ISAURA	SANTOS	NAVARRO
9	PATRICIA VICTORIA	CORDOBA	RIOS
10	VALENTINA	ESPEJO	GOMEZ

```
# i 24 more rows
```

4.1 Selección del piloto (15 estudiantes)

Se selecciona un subconjunto de 15 estudiantes **dentro de la muestra de 34 ya elegida** (no son estudiantes distintos), también de forma aleatoria y con semilla fija, para poder trazar exactamente quiénes conforman el piloto.

```
set.seed(15) # semilla fija distinta, exclusiva para el piloto - no cambiar
```

```
piloto_estudiantes <- muestra |>
  slice_sample(n = 15)
```

```
piloto_estudiantes
```

```
# A tibble: 15 x 3
```

	NOMBRES	PRIMER_APELLIDO	SEGUNDO_APELLIDO
	<chr>	<chr>	<chr>
1	Danna Valentina	Córdoba	Pabón
2	SANTIAGO	VAHOS	CANO

3	Keder Julian	Madera	Polo
4	Jesús David	Arias	Altamar
5	Lorena Marcela	Oviedo	Miranda
6	Miguel	Torres	Jiménez
7	GABRIELA	ROJAS	VILLALOBOS
8	Laura Cristina	Soto	Blandon
9	JOSE ALEJANDRO	ESCUDERO	ZAPATA
10	ANA PAULA	CHAVARRÍA	TORRES
11	JUAN CAMILO	GIRALDO	TORRES
12	Juan Felipe	Echeverry	Valencia
13	JUAN JOSÉ	GIRÓN	BECERRA
14	VALENTINA	ESPEJO	GOMEZ
15	TOMÁS UBERNEY	GÓMEZ	GONZÁLEZ

```
write.csv(piloto_estudiantes, "piloto_seleccionado.csv", row.names = FALSE)
```

4.2 Lista de reserva

Antes de enviar el piloto, se genera una lista de reserva sobre la base completa de 1130 estudiantes (excluyendo a los 34 ya seleccionados), para tener de dónde sacar reemplazos si hay no respuesta, sin improvisar la elección.

```
set.seed(2027) # semilla fija, distinta a la de la muestra principal

reserva <- datos |>
  anti_join(muestra, by = c("NOMBRES", "PRIMER_APELLIDO", "SEGUNDO_APELLIDO")) |>
  slice_sample(n = 15)

reserva
```

```
# A tibble: 15 x 3
  NOMBRES          PRIMER_APELLIDO SEGUNDO_APELLIDO
  <chr>            <chr>            <chr>
1 Andrés Mauricio Zambrano      Peña
2 JUAN MANUEL      GONZALEZ          RENDON
3 JUAN ESTEBAN     MARTINEZ          SERNA
4 DYLAN STIV       LÓPEZ             ESCOBAR
5 María Jose       Giraldo           Vallejo
6 JOSE MANUEL      GASTELBONDO       OROZCO
7 Jehily Fernanda Torres          Rivera
8 JOSE FERNANDO    CARDENAS          CARDONA
```

9 JERONIMO	CASTRO	ALVAREZ
10 Manuel	Rivera	Estrada
11 Adrien Jacques Louis	VIGNALOU-PERER	<NA>
12 Jhon Kenedy	Ojeda	Urbano
13 Nathaly	Caro	Orozco
14 MIGUEL	VÉLEZ	BERNAL
15 SARA	RESTREPO	GIL

```
write.csv(reserva, "reserva_reemplazos.csv", row.names = FALSE)
```

4.3 Ronda de contingencia 1 — registro de no respuesta

Bitácora: se envió el correo de invitación a los 15 estudiantes de `piloto_seleccionado.csv` (sección 4.1). Tras el plazo de espera y el recordatorio, **solo 2 de los 15 respondieron** (tasa de respuesta 13%). Se activa el plan de contingencia: se reemplazan los 13 no respondientes por 13 estudiantes nuevos, sacados de la base completa y excluyendo tanto a los 34 de la muestra como a la reserva ya generada, para no invitar dos veces a la misma persona ni cruzar las listas de reemplazo.

```
set.seed(153) # nueva semilla, exclusiva de esta ronda de contingencia

contingencia_piloto <- datos |>
  anti_join(bind_rows(muestra, reserva),
            by = c("NOMBRES", "PRIMER_APELLIDO", "SEGUNDO_APELLIDO")) |>
  slice_sample(n = 13)

contingencia_piloto
```

```
# A tibble: 13 x 3
  NOMBRES          PRIMER_APELLIDO SEGUNDO_APELLIDO
  <chr>            <chr>           <chr>
1 Sara Manuela    Cabrera         Berrio
2 SIMON ANDRES    GOMEZ           ARIAS
3 JOHAN ADRIAN    BENITEZ         ESCOBAR
4 Camilo Andrés  Córdoba        Cerón
5 Karol Daniela   Reyes           Parra
6 ANDRES          PEREZ           BORJAS
7 GEORGE ANDRES   COLOBON         ASCANIO
8 Daniel Alejandro Rúa             Vallejo
9 STEPHANY ALEJANDRA ORJUELA        RUBIO
10 JOSE ALEJANDRO  AGUIRRE         RAMIREZ
```

11	JHONATAN ALEXIS	RUIZ	HERMOSA
12	BRAYAN ALEXIS	HERNANDEZ	ORTEGA
13	Heidy Jessenia	Lugo	Martinez

```
write.csv(contingencia_piloto, "piloto_contingencia_ronda1.csv", row.names = FALSE)
```

El piloto efectivo queda entonces conformado por los 2 que ya respondieron del envío original, más los que respondan de estos 13 nuevos de la ronda 1.

4.4 Ronda de contingencia 2

Dado el historial de baja respuesta (2/15 13% en la ronda original), se prepara de una vez una segunda ronda de contingencia, por si la ronda 1 repite una tasa de respuesta baja. Se excluyen todos los ya contactados hasta el momento: los 34 de la muestra, la reserva, y los 13 de la ronda 1.

```
set.seed(154) # nueva semilla, ronda 2 de contingencia

contingencia_piloto_2 <- datos |>
  anti_join(bind_rows(muestra, reserva, contingencia_piloto),
            by = c("NOMBRES", "PRIMER_APELLIDO", "SEGUNDO_APELLIDO")) |>
  slice_sample(n = 15)

contingencia_piloto_2
```

```
# A tibble: 15 x 3
  NOMBRES          PRIMER_APELLIDO SEGUNDO_APELLIDO
  <chr>            <chr>            <chr>
1 Paula Andrea    Montaña          Casas
2 NICOLLET        DIAZ             TALEGUA
3 VALENTINA       RUEDA            GOMEZ
4 ANGIE PAOLA     SIERRA           PAVA
5 XIMENA          POSADA           ARENAS
6 NAZLY YAMILE    COELLO           RODRIGUEZ
7 Andres Felipe   Cifuentes        Marin
8 JUAN            HIGUITA          DAVID
9 SANTIAGO        MONSALVE         BEDOYA
10 Luisa Fernanda Mazo             Perez
11 MIGUEL ANGEL   BETANCUR         GONZALEZ
12 DANIEL FELIPE  VILLEGAS         IBARRA
13 Mario Andrés   García           Marín
```

14 Sergio Andres Velasquez Mantilla
 15 Francisco Andres Toncel Quintero

```
write.csv(contingencia_piloto_2, "piloto_contingencia_ronda2.csv", row.names = FALSE)
```

4.5 Consolidado de seguimiento del piloto

Para no manejar tres archivos sueltos, se consolida todo el seguimiento del piloto en una sola tabla, marcando de qué ronda viene cada persona y si ya respondió (columna `estado`, se actualiza manualmente conforme lleguen las respuestas).

```
seguimiento_piloto <- bind_rows(
  piloto_estudiantes |> mutate(ronda = "original", estado = "pendiente"),
  contingencia_piloto |> mutate(ronda = "contingencia_1", estado = "pendiente"),
  contingencia_piloto_2 |> mutate(ronda = "contingencia_2", estado = "pendiente")
)

seguimiento_piloto
```

```
# A tibble: 43 x 5
  NOMBRES          PRIMER_APELLIDO SEGUNDO_APELLIDO ronda    estado
  <chr>            <chr>            <chr>            <chr>    <chr>
1 Danna Valentina Córdoba      Pabón            original pendiente
2 SANTIAGO        VAHOS             CANO             original pendiente
3 Keder Julian    Madera            Polo             original pendiente
4 Jesús David     Arias             Altamar          original pendiente
5 Lorena Marcela  Oviedo            Miranda          original pendiente
6 Miguel          Torres            Jiménez          original pendiente
7 GABRIELA        ROJAS             VILLALOBOS       original pendiente
8 Laura Cristina Soto              Blandon          original pendiente
9 JOSE ALEJANDRO  ESCUDERO          ZAPATA           original pendiente
10 ANA PAULA      CHAVARRÍA         TORRES           original pendiente
# i 33 more rows
```

```
write.csv(seguimiento_piloto, "piloto_seguimiento.csv", row.names = FALSE)
```

Nota: en `piloto_seguimiento.csv`, actualicen manualmente la columna `estado` a "respondió" o "no respondió" conforme lleguen las respuestas. Los 2 que respondieron en la ronda original se marcan aparte al momento de calcular S_{real} en la sección 2.1 — solo entran al cálculo quienes efectivamente contestaron, sin importar de qué ronda vinieron.

5. Exportación y obtención de contacto

La universidad no facilita directamente los correos de los seleccionados; es el equipo quien, a partir del nombre completo, los busca en el **directorio institucional público de la universidad** y envía manualmente el correo de invitación a participar en la encuesta a cada estudiante seleccionado.

```
write.csv(muestra, "muestra_seleccionada.csv", row.names = FALSE)
```

El archivo `muestra_seleccionada.csv` sirve como lista de trabajo para ese proceso de búsqueda y envío, y para marcar quién ya respondió.

6. Trazabilidad del proceso

- **Marco muestral:** listado oficial de 1130 estudiantes matriculados en Ecuaciones Diferenciales (2026-01), entregado por el coordinador de la asignatura.
- **Diseño:** Muestreo Aleatorio Simple, sin reemplazo (`slice_sample` por defecto no repite filas).
- **Tamaño de muestra:** 34 estudiantes, calculado con 95 % de confianza y error admisible de 0.5 horas.
- **Semilla muestra principal:** 2026.
- **Semilla piloto original:** 15.
- **Semilla reserva:** 2027.
- **Semilla contingencia ronda 1:** 153 — activada porque solo 2 de los 15 del piloto original respondieron.
- **Semilla contingencia ronda 2:** 154 — preparada por si la ronda 1 repite baja respuesta.
- **Instrumento:** encuesta breve con la pregunta “¿Cuántas horas duerme en promedio por noche durante el semestre académico?”, aplicada a los estudiantes seleccionados tras obtener sus correos institucionales.

7. Hoja de ruta

1. **Buscar los correos** de los 34 seleccionados en `muestra_seleccionada.csv` en el directorio institucional de la universidad, usando nombre y apellidos.
2. **Enviar la encuesta piloto** a los 15 de `piloto_seleccionado.csv` (sección 4.1). (*Ya hecho: 2 de 15 respondieron.*)
3. **Activar contingencia ronda 1** (sección 4.3): se sacaron 13 personas nuevas (`piloto_contingencia_ronda1.csv`) para reemplazar a quienes no respondieron. (*Ya hecho.*)
4. **Enviar la encuesta a la ronda 1.** Si la respuesta vuelve a ser baja, usar la ronda 2 ya preparada (`piloto_contingencia_ronda2.csv`, sección 4.4) para completar el piloto.

5. **Marcar el estado de cada persona** en `piloto_seguimiento.csv` (sección 4.5) conforme lleguen respuestas.
6. **Con las respuestas efectivas del piloto** (sin importar de qué ronda vengan), correr el chunk `recalculo-con-piloto` (sección 2.1) para obtener `S_real` y `n_real`.
7. **Comparar `n_real` con 34:**
 - Si `n_real <= 34`: ya tienen tamaño suficiente, continúan encuestando al resto de los 34 originales (aplicando el mismo protocolo de recordatorio/reemplazo si hace falta).
 - Si `n_real > 34`: seleccionar los estudiantes faltantes (el chunk de la sección 2.1 lo hace automáticamente con `anti_join`), buscar sus correos y encuestarlos también.
8. **Enviar la encuesta al resto de la muestra**, aplicando siempre el mismo protocolo de reemplazo documentado.
9. **Consolidar todas las respuestas** en una sola tabla (nombre + horas de sueño reportadas), incluyendo la tasa de respuesta final.
10. **Calcular el promedio muestral $\bar{y}$** y su error estándar, y redactar la sección de resultados del informe final citando estos números.
11. **Documentar en el informe** el ajuste de MAE a MAS, el supuesto inicial de S, el recálculo con el piloto, y el manejo completo de la no respuesta (rondas 1 y 2 de contingencia) — esto ya está construido en las secciones 1, 2.1, 4.2, 4.3 y 4.4, y responde de antemano a las preguntas que un profesor exigente haría sobre el rigor del diseño.